Documentação do projeto ETL Mercatto

Material de estudo para a equipe (Gabriel, Lucas e Marcus) preparar a defesa. Para cada semana: **o que foi feito**, **como executar**, **código para estudar**, **resultados**, **interpretação** e **para a defesa** (o que explicar em um minuto e perguntas prováveis). Todo número vem de arquivos gerados por scripts versionados (`etl/diagnostico/`, em `saida/`); `diagnostico/verificar_documentacao.py` confere isso (ver a seção "Como esta documentação foi verificada").

Resumo do projeto: como foi feito

Em uma frase. Integramos quatro fontes heterogêneas de uma rede de varejo num repositório analítico (`stg` → `cnf` → `dw` → `abt`), registramos cada decisão de transformação e usamos o resultado para medir, no Orange, quanto o vazamento de dados infla o desempenho de um modelo que prevê a recompra.

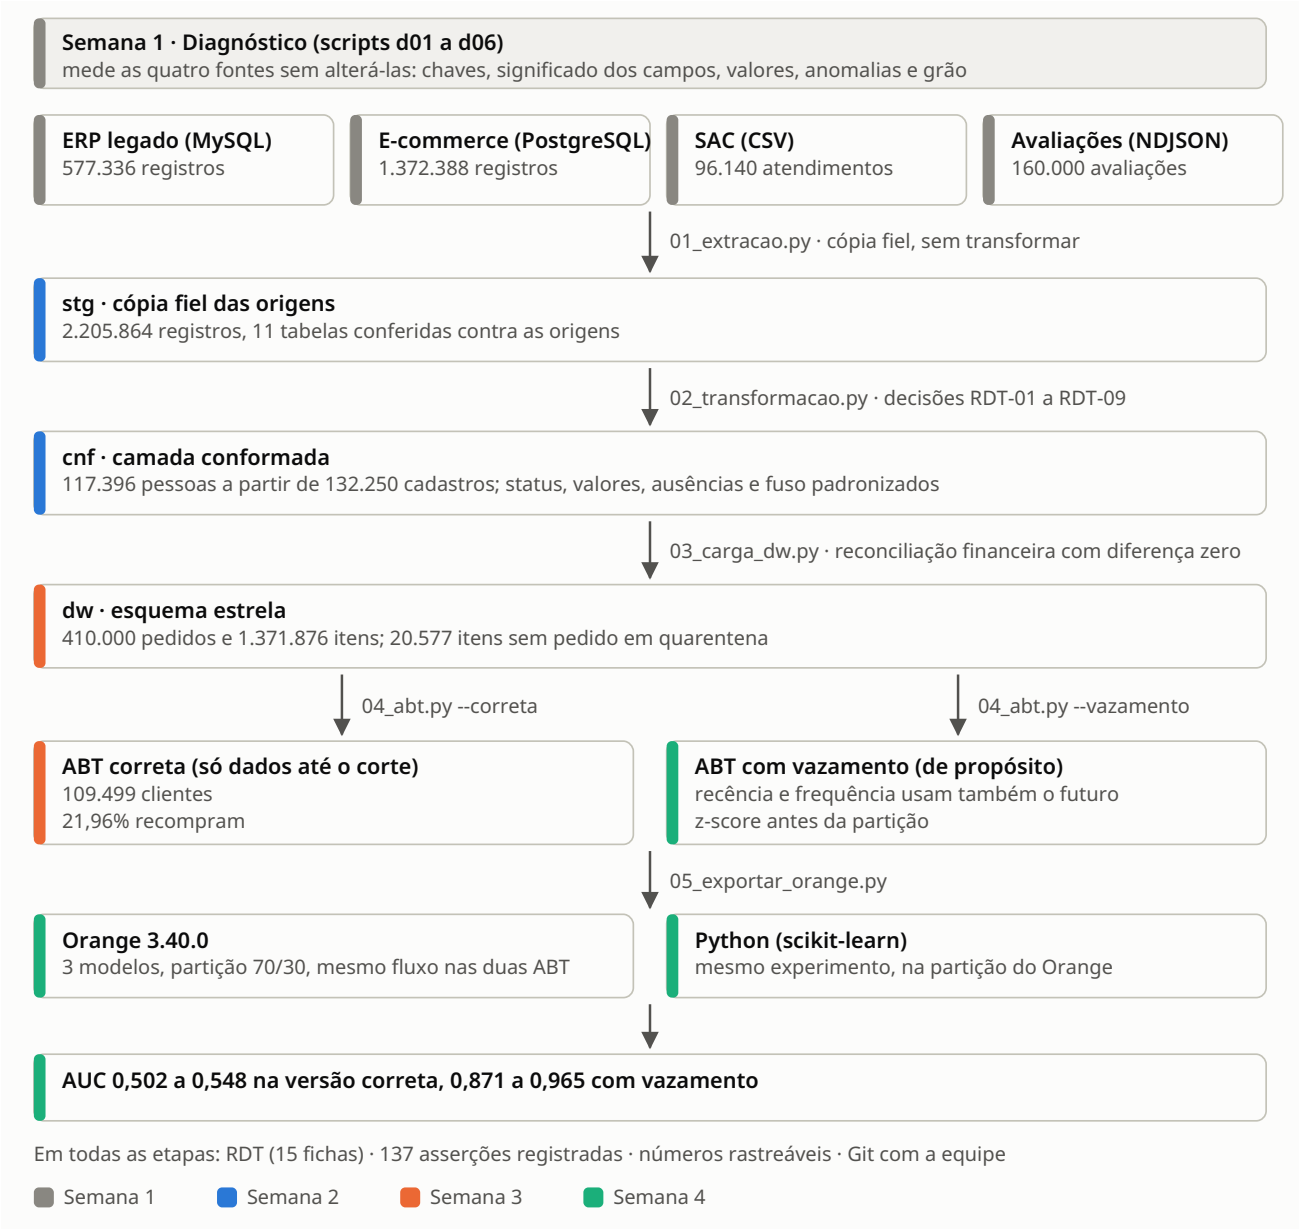


Figura 1. O projeto inteiro numa página: cada seta é um script, cada cor é a semana em que a etapa foi feita, e os números vêm dos arquivos de `saida/`.

Passo a passo, em ordem.

1. **Medir antes de mexer (Semana 1).** Seis scripts de diagnóstico mediram as fontes sem alterá-las (2.205.864 registros) e responderam a cinco perguntas: que chaves ligam as fontes, onde o significado dos campos diverge, o que os valores significam, quais anomalias existem e qual o grão das tabelas-fato.

2. **Extrair sem alterar e conformar (Semana 2).** A `stg` guarda a cópia fiel das origens; a `cnf` aplica as decisões: unificar clientes (os cadastros viram 117.396 pessoas), conformar status, valores, categorias, ausências e fuso. Cada decisão ganhou uma ficha do RDT.
3. **Carregar, reconciliar e montar a tabela de análise (Semana 3).** O DW em estrela (410.000 pedidos) foi carregado e reconciliado com as origens, com diferença zero. A ABT, com 109.499 clientes e 21,96% de positivos, foi construída só com dados até o corte e testada contra o DW cortado em 30/06/2025.
4. **Medir o efeito do vazamento (Semana 4).** Construímos uma segunda versão da ABT, de propósito, com vazamento, e rodamos o mesmo fluxo no Orange nas duas. Com vazamento, a AUC sobe de cerca de 0,5 para 0,87 a 0,97. O experimento foi repetido em Python, na mesma partição, e o RDT ganhou as fichas 14 e 15, a tabela-resumo e a reflexão.
5. **Provar a reprodutibilidade (fase final).** Apagamos o destino, rodamos o pipeline de novo e comparamos impressões digitais; criamos verificadores que procuram cada número dos textos nos arquivos gerados.

Princípios que guiaram tudo.

- **Evidência antes de decisão:** cada ficha do RDT traz o que o dado mostrava, as alternativas, a decisão, o que se perde, os registros afetados e a asserção que guarda a decisão.
- **Nada se corrige na origem:** as origens são somente leitura, e a `stg` é cópia fiel.
- **Verificação automática:** 137 asserções registradas no banco, todas aprovadas.
- **Todo número é rastreável:** sai de um script versionado e de um arquivo de `saida/`, e os verificadores conferem os textos.
- **Hipóteses não são conclusões:** relatamos o que o dado mostrou, inclusive quando a hipótese do roteiro caiu (por exemplo, o formato do CPF não muda com o tempo).

Como o trabalho foi conduzido. Em ciclos semanais, com o apoio do agente Claude Code sob regras permanentes (`CLAUDE.md`): não abrir os arquivos que revelam como as anomalias foram fabricadas, nunca escrever nas origens e deixar o Git com a equipe. Houve duas paradas obrigatórias: a equipe montou os fluxos no Orange (parada 4.3) e conferiu as fichas do RDT (parada 4.6). A equipe também decidiu os pontos abertos (alcance do teste do zero, dump no repositório, restauração das notas da Semana 1).

Limites que declaramos. O status do pedido na ABT é o do retrato dos dados, não o do corte; avaliações não ligam a cliente; a unificação de clientes não tem verdade externa para conferência; o Python não reproduz o Orange ao centésimo; e não provamos que o seed refaz as origens.

Visão geral

Pergunta do projeto. Um cliente que comprou até 30/06/2025 recompra entre 01/07/2025 e 28/09/2025?

Fontes. Quatro, heterogêneas: o ERP legado (MySQL, tabelas `CLIENTES`, `PRODUTOS`, `PEDIDOS` e `ITENS_PEDIDO`), o e-commerce (PostgreSQL, esquema `shop`), o CSV do SAC (atendimentos) e o NDJSON de avaliações de marketplace. As origens são **somente leitura**.

Camadas (cada uma é um esquema do banco `mercatto_dw`):

Camada	O que guarda	Criada por
`stg`	cópia fiel das quatro fontes, sem filtro	`01_extracao.py`
`cnf`	dados conformados: clientes unificados, status, valores, datas e ausências tratados	`02_transformacao.py`
`dw`	esquema estrela (dimensões e fatos)	`03_carga_dw.py`
`abt`	tabela-base de análise: uma linha por cliente, com os atributos e o alvo	`04_abt.py`

Depois da `abt`, `05_exportar_orange.py` grava os CSV que o Orange lê, e `diagnostico/experimento_python.py` repete o experimento em Python.

Glossário mínimo.

- *Corte*: 30/06/2025. Só dados até essa data podem virar atributo. *Alvo*: comprou na janela de 01/07/2025 a 28/09/2025.
- *Grão*: o que uma linha de uma tabela-fato representa.
- *RDT*: Registro de Decisões de Transformação. Cada ficha traz evidência, alternativas, decisão, o que se perde, registros afetados e a asserção que guarda a decisão.

- *Asserção*: verificação automática gravada em `qa.execucao_assercao`. Uma falha fica registrada e marcada `FALHA` no terminal, mas **não interrompe a etapa**; a exceção é a reconciliação financeira da etapa 3, que aborta se a diferença passar de 0,1%.
- *Vazamento*: o treino recebe informação sobre o alvo que não existiria no momento da predição.
- *Acurácia balanceada*: (recall + especificidade) / 2, com a classe 1 (recompra) como positiva.

Onde está cada coisa.

Documento	Para quê
`README.md` (raiz)	mapa do repositório e execução
`ETL/docs/RDT.md` e `RDT.pdf`	as 15 decisões de transformação, com tabela-resumo e reflexão
`ETL/relatorio/semana1/notas_para_defesa.md`	conclusões da Semana 1 e decisões D1 a D10 com as alternativas descartadas
`ETL/relatorio/notas_para_defesa_semanas_2_4.md`	decisões D11 a D53 com as alternativas descartadas
`ETL/relatorio/semana4/resultados_experimento.md` e `.pdf`	resultado do experimento de vazamento
`ETL/relatorio/semana4/GUIA_ORANGE.md`	como montar os fluxos no Orange
`ETL/relatorio/PROGRESSO.md`	histórico por semana
`ETL/docs/DICIONARIO_ABT.md`	os atributos da tabela-base

Regra para todos os comandos: rodar a partir da pasta `ETL/`, com o Python dentro do contêiner `etl`. Para subir o ambiente:

```
cd ETL
echo 'ESCALA=1.0' > .env
docker compose up -d --build
docker compose logs -f seed       # esperar "ambiente pronto."
```

Semana 1 — Diagnóstico das fontes

O que foi feito

Sem transformar nada, medimos as quatro fontes com seis scripts (`d01` a `d06`) e o perfilamento-modelo (`00_perfilamento.py`). O perfilamento usa só uma amostra (`LIMIT 200000`); por isso todas as contagens do relatório foram refeitas em SQL sobre as tabelas inteiras. O relatório (`relatorio/semana1/diagnostico_semana1.pdf`) responde a cinco perguntas: (a) que chaves ligam as fontes, (b) onde há heterogeneidade semântica, (c) o que significam os valores, (d) quais anomalias existem, (e) qual o grão das tabelas-fato.

Como executar

```
docker compose exec etl python 00_perfilamento.py
for s in d01_volumes_periodos d02_chaves d03_semantica d04_valores d05_anomalias d06_grao; do
  docker compose exec etl python -m diagnostico.$s
done
```

Saídas em `saida/diagnostico/`. O verificador do relatório lê o texto pela entrada padrão (rodá-lo sem entrada apaga o resultado anterior): `git show c50dbc2:ETL/relatorio/semana1/diagnostico_semana1.md | docker compose exec -T etl python -m diagnostico.verificar_relatorio`.

Código para estudar

Todos os caminhos são relativos a `ETL/etl/`. A coluna "Estudar" diz o que ler primeiro.

Arquivo	O que faz	Estudar
`config.py`	conexões somente leitura das origens e do DW; as datas analíticas (`DATA_CORTE`, `JANELA_ALVO_DIAS`, `DATA_FIM_ALVO`). Fornecido, não se altera	ler inteiro; é de onde vem o corte de 30/06/2025

Arquivo	O que faz	Estudar
`diagnostico/comum.py`	funções compartilhadas: `leg` e `ecom` (consultas nas origens), `cpf_valido` (dígito verificador), `normaliza_texto`, `registrar` e `salvar_csv` (gravam os números em `saida/diagnostico/`), `Relatorio`	`cpf_valido` e `registrar`: por `registrar` todo número chega ao relatório
`00_perfilamento.py`	perfilamento-modelo fornecido, com amostra de `LIMIT 200000`	só para saber explicar por que ele não serve para contagens
`diagnostico/d01_volumes_periodos.py`	volumes de cada fonte e cobertura temporal	rápido
`diagnostico/d02_chaves.py`	pergunta (a): cobertura do CPF, e-mail, telefone e das referências do SAC e do NDJSON	o teste do CPF válido e a consistência entre o CPF do atendimento e o dono do pedido
`diagnostico/d03_semantica.py`	pergunta (b): os cinco casos de heterogeneidade semântica	o caso de `CANCELADO` e o de `SITE`
`diagnostico/d04_valores.py`	pergunta (c): `flags_sql` e `por` testam as fórmulas H1 a H6 em SQL, sobre todos os pedidos	**prioridade alta**: é a prova de que `total_amount` não inclui o frete
`diagnostico/d05_anomalias.py`	pergunta (d): `reg` registra anomalias de uma fonte só ("agora"); `reg2` registra as que dependem de integrar, com limite inferior e superior ("depois")	entender por que o "depois" tem dois limites
`diagnostico/d06_grao.py`	pergunta (e): verificações que sustentam o grão	a colisão de ids entre os dois sistemas
`diagnostico/verificar_relatorio.py`	confere os números do relatório contra `numeros.json`	só para saber que existe

Resultados

- **Volume:** 2.205.864 registros (577.336 no legado, 1.372.388 no e-commerce, 96.140 atendimentos e 160.000 avaliações).
- **Chave de clientes:** só o CPF liga os cadastros. O CPF válido casa 11.875 dos 47.250 clientes do legado (25,13%); e-mail e telefone casam 0.
- **SAC e avaliações ligam ao cliente pelo CPF, não ao pedido.** O CPF do atendimento é o do dono do pedido em 1 de 96.140 casos; o CPF do SAC casa com algum cadastro em 93,77%.
- **Valores:** `total_amount` do e-commerce é a mercadoria líquida, sem frete (a fórmula bruto − desconto de linha vale em 100% dos pedidos). `VALOR_TOTAL` do legado é a mercadoria líquida mais o frete: vale em 96,92% dos pedidos e em 100% quando o desconto `-1` é lido como zero.
- **Status:** `CANCELADO` responde por 12,13% dos pedidos do legado e provavelmente reúne dois significados que o e-commerce separa (cancelado e pagamento recusado).
- **Anomalias dentro de uma fonte:** 2.250 pares de clientes duplicados no legado; 1.025 entregas com data `1900-01-01`; 20.577 itens sem pedido (5.868 no legado e 14.709 no e-commerce).
- **Anomalias que só aparecem na integração:** 78 pedidos (limite superior) trocam de lado do corte ou do fim do alvo conforme o fuso. Entre os clientes de CPF comum, 84,85% compraram nos dois sistemas antes do corte; sem unificar, 32,26% teriam ao menos uma linha da ABT com o rótulo errado.
- **Grão:** `fato_pedido` tem uma linha por pedido de um sistema, chave (sistema, id). Os 130.000 ids do legado também existem no e-commerce, então ignorar o sistema daria 280.000 pedidos em vez de 410.000.

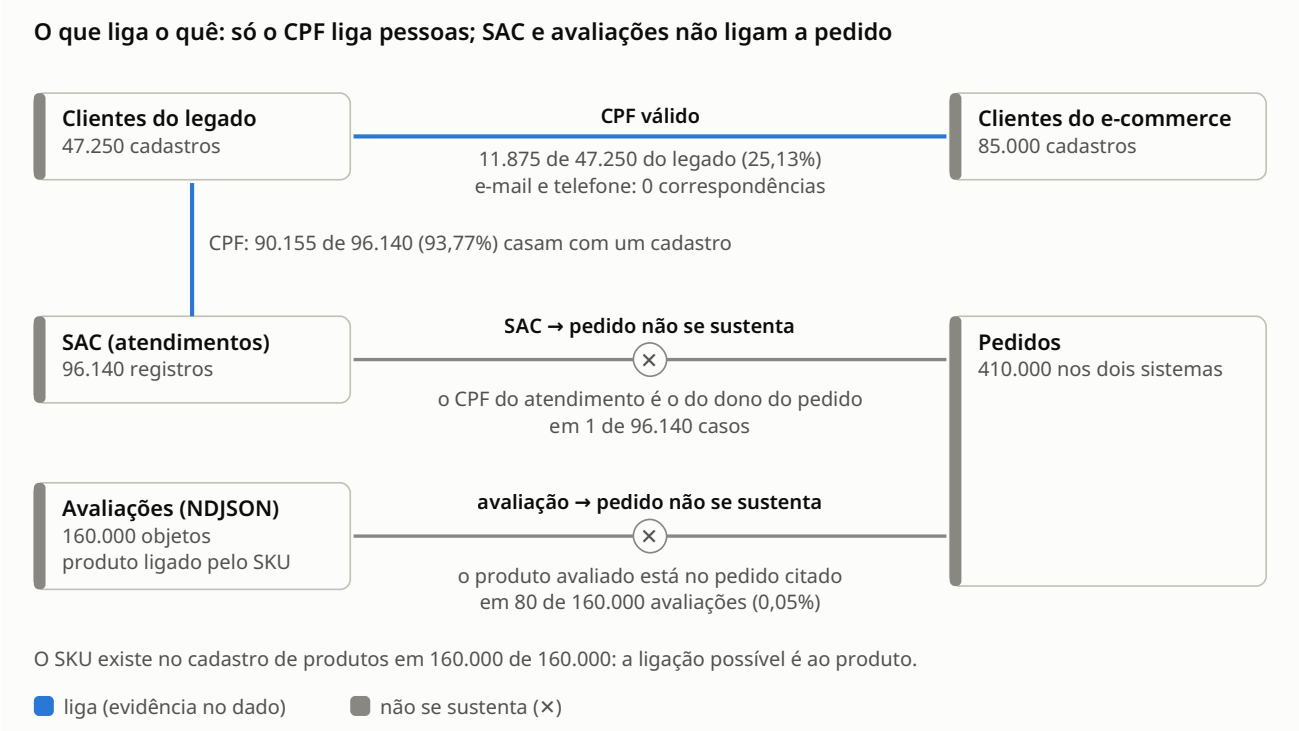


Figura 2. Onde há ligação de verdade no dado (azul) e onde a ligação sugerida pelo dicionário não se sustenta (cinza).

Interpretação

O diagnóstico mostra que **o dado não é confiável como vem**: o mesmo rótulo ("valor total", "cancelado") significa coisas diferentes em cada sistema, e as ligações que o dicionário sugere (SAC → pedido) não se sustentam. Cada achado vira uma decisão da Semana 2. O mais importante para o alvo é a identidade do cliente: quem compra nos dois sistemas só é visto por inteiro depois de unificar, e é isso que faz a recompra ser medida direito.

Para a defesa

- **Em um minuto:** "Medimos as quatro fontes sem alterá-las e descobrimos que os rótulos enganam: o total do legado inclui frete e o do e-commerce não, e o SAC liga ao cliente, não ao pedido."
- **Como vocês sabem que `total_amount` não inclui frete?** Testamos seis fórmulas contra todos os pedidos, em SQL: só "bruto − desconto de linha" bate em 100% dos pedidos do e-commerce.
- **Por que não usar e-mail para ligar clientes?** A interseção entre os dois sistemas é 0.
- **Por que a amostra do `00_perfilamento.py` não basta?** Ela trunca três tabelas; contagens e reconciliações precisam da tabela inteira.

Resumo da semana

Semana 1: medir sem transformar. Seis scripts mediram as quatro fontes (2.205.864 registros) e mostraram que o dado não pode ser integrado às cegas. Só o CPF liga cadastros (casa 25,13% dos clientes do legado); o SAC e as avaliações ligam ao cliente, não ao pedido; `VALOR_TOTAL` inclui o frete e `total_amount` não. Apareceram 2.250 pares de clientes duplicados, 20.577 itens sem pedido e 78 pedidos cujo lado do corte depende do fuso. Esses achados são a matéria-prima das decisões das semanas seguintes. **Para levar:** o diagnóstico não corrige nada; ele dá a evidência de cada decisão.

Semana 2 — Extração e conformação

O que foi feito

- **`01_extracao.py`:** copia as quatro fontes para o esquema `stg`, sem filtro, e confere cada contagem com a origem. É carga completa, porque as origens não têm coluna de atualização (RDT-01).

- **`02_transformacao.py`:** produz o esquema `cnf`. Unifica clientes dos dois sistemas e funde duplicatas do legado (RDT-02 e 03); conforma status (RDT-04), valores (RDT-05 e 06), categorias de produto (RDT-07), ausências (RDT-08) e fuso (RDT-09); liga SAC e avaliações.
- **`docs/RDT.md`:** fichas RDT-01 a RDT-09, cada uma com as seis partes exigidas.

Como executar

```
docker compose exec etl python 01_extracao.py
docker compose exec etl python 02_transformacao.py
docker compose exec etl python -m diagnostico.e01_conferencia_stg      # stg contra o diagnóstico da Semana 1
docker compose exec etl python -m diagnostico.rdt_registros_afetados   # números do RDT
docker compose exec etl python -m diagnostico.renderiza_rdt            # gera saida/rdt/RDT.md
cp saida/rdt/RDT.md docs/RDT.md
```

Tempos medidos no teste do zero: `01_extracao` 24 s e `02_transformacao` 471 s (pouco menos de oito minutos).

Código para estudar

Arquivo	O que faz	Estudar
`01_extracao.py`	`extrai_mysql`, `extrai_postgres`, `extrai_sac` e `extrai_avaliacoes` copiam cada fonte para a `stg` (colunas de procedência `_fonte`, `_extraido_em` e `_linha_origem`); `cria_tabela` recria a tabela; `verifica` e `confere_colunas` comparam a `stg` com a origem	`verifica` (a prova de que nada foi perdido) e a regra de não transformar nada na `stg`
`qualidade/assercoes.py`	fornecido: a classe `Suite` (`igual`, `entre`, `sem_nulos`, `unico`, `dominio`, `cardinalidade_preservada`, `sem_orfaos`); `registrar` grava em `qa.execucao_assercao`	entender, porque toda etapa o usa; uma falha **não interrompe** a etapa
`02_transformacao.py`	o coração da semana. `unifica_clientes` (cada pessoa é um componente conexo de um grafo de pareamento: duplicata do legado, CPF válido com nome, CPF inválido com nome e UF) · `conforma_status` · `conforma_valores` · `conforma_categorias` · `trata_datas_e_ausencias` · `monta_pedido` (junta as decisões na tabela de pedidos conformada) · `liga_sac_e_avaliacoes`	**prioridade alta**: `unifica_clientes` e `conforma_valores`; depois `trata_datas_e_ausencias`
`diagnostico/e01_conferencia_stg.py`	confere a contagem da `stg` contra o diagnóstico da Semana 1	rápido
`diagnostico/rdt_registros_afetados.py`	calcula o item (e) das fichas: registros afetados por cada decisão, em SQL sobre tabelas inteiras	ver como um número do RDT nasce
`diagnostico/renderiza_rdt.py` e `rdt/RDT.template.md`	geram `docs/RDT.md` trocando cada marcador `{{chave}}` pelo número do JSON; a geração falha se uma chave não existir	entender por que "nenhum número foi digitado à mão"

Mapa decisão → função: RDT-02 e 03 em `unifica_clientes`; RDT-04 em `conforma_status`; RDT-05 e 06 em `conforma_valores`; RDT-07 em `conforma_categorias`; RDT-08 e 09 em `trata_datas_e_ausencias`.

Resultados

- **Extração:** a `stg` tem as mesmas contagens das origens nas 11 tabelas (`saida/extracao/contagens_stg.csv`), 32 asserções e 0 falhas.
- **Clientes:** os 132.250 registros de cadastro viram 117.396 pessoas: 12.604 nos dois sistemas, 72.396 só no e-commerce e 32.396 só no legado. 14.854 registros foram unidos a outra identidade (11,23% dos registros), 2.250 deles duplicatas do legado.
- **Status:** 52.177 pedidos são cancelados (12,73% dos pedidos). Cancelado conta como não-compra.
- **Valor:** `valor_total` = mercadoria − desconto + frete nos dois sistemas. Isso difere do `total_amount` cru em 279.984 pedidos do e-commerce (99,99%), justamente por acrescentar o frete.
- **Fuso:** a régua é a hora de Brasília; com UTC, 78 pedidos (0,02%) trocariam de lado do corte ou do fim do alvo.
- **Transformação:** 46 asserções e 0 falhas.

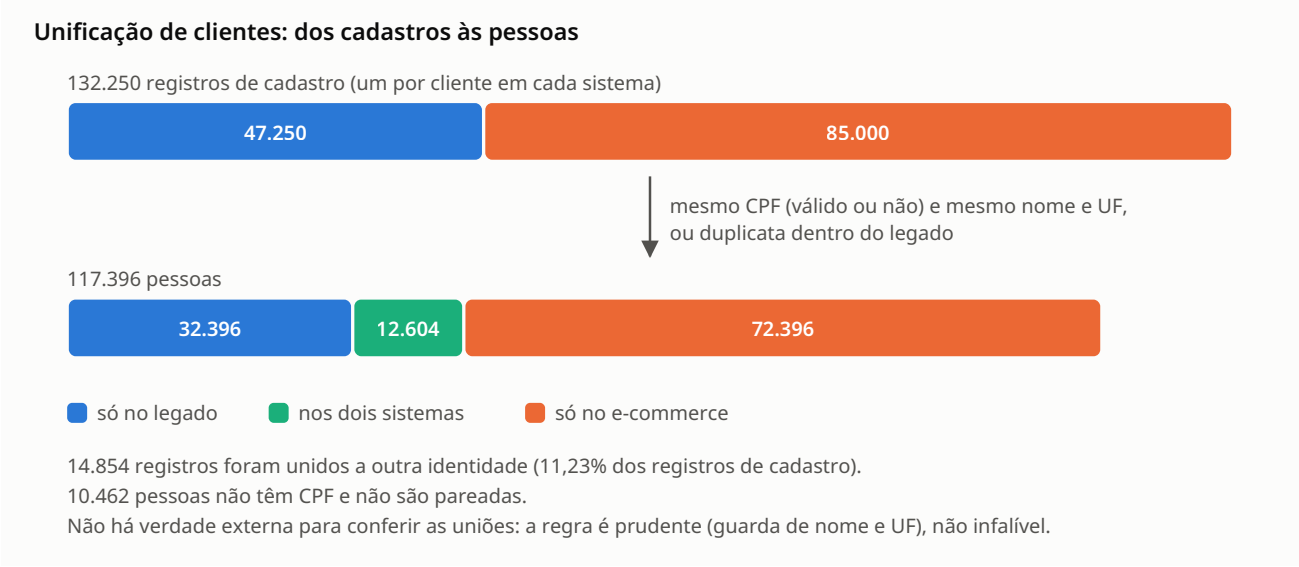


Figura 3. Dos cadastros às pessoas: as barras têm a mesma escala, então o encolhimento é real.

Interpretação

As decisões da Semana 2 são de **julgamento**: unir por CPF (válido ou não) com guarda de nome e UF reduz homônimos, mas não há verdade externa para conferir as 14.854 uniões. Já a decisão de somar o frete ao total do e-commerce **não** é um julgamento no mesmo sentido: o dado prova a fórmula, e só falta uniformizá-la. Cada decisão custa algo (por exemplo, o motivo de cancelamento do legado se perde) e o RDT registra isso.

Para a defesa

- **Em um minuto:** "Conformamos as fontes numa camada `cnf` sem apagar a cópia fiel `stg`; cada decisão tem uma ficha com evidência, alternativas, o que se perde e a asserção que a protege."
- **Por que unir clientes por CPF e não por e-mail?** O e-mail não casa nenhum registro entre os sistemas; o CPF casa e, nos pares, o nome concorda em quase todos os casos.
- **Por que o frete foi somado ao total do e-commerce, e não retirado do legado?** Porque o DDL define `valor_total` como mercadoria + frete − desconto, e retirar o frete do legado tiraria da ABT um atributo real (RDT-05).
- **O que se perde ao unificar?** Pessoas sem CPF (10.462) não são pareadas; a decisão é prudente, e não perfeita.

Resumo da semana

Semana 2: extrair sem alterar e conformar com decisões registradas. A `stg` guarda a cópia fiel das 11 tabelas de origem (32 asserções, 0 falhas), e a `cnf` as conforma (46 asserções, 0 falhas). Os 132.250 registros de cadastro viram 117.396 pessoas; 52.177 pedidos são cancelados e contam como não-compra; `valor_total` passa a ter a mesma fórmula nos dois sistemas; a régua de tempo é a hora de Brasília. Cada decisão tem uma ficha (RDT-01 a RDT-09) com evidência, alternativas, o que se perde e a asserção que a guarda. **Para levar:** unir clientes é julgamento sem verdade externa (14.854 registros unidos a outra identidade), e por isso a decisão é prudente e documentada.

Semana 3 — Carga do DW, reconciliação e ABT

O que foi feito

- **`03_carga_dw.py`:** carrega o esquema estrela a partir de `cnf`, põe em quarentena os itens sem pedido e **reconcilia** as somas financeiras com as origens (RDT-10 a 13).
- **`04_abt.py --correta`:** monta `abt.recompra_90d`, com todos os atributos calculados só com dados até o corte, e testa isso (RDT-14).
- Dump do DW em `entregas/dw_semana3.sql.gz`.

Como executar

```
docker compose exec etl python 03_carga_dw.py          # dw + reconciliação (56 s no teste do zero)
docker compose exec etl python 04_abt.py --correta     # abt.recompra_90d (54 s)
```

Código para estudar

Arquivo	O que faz	Estudar
`03_carga_dw.py`	`carrega_dim_tempo`, `limpa_dw`, `carrega_dimensoes`, `carrega_fato_pedido`, `carrega_fato_item` (itens sem pedido vão para a quarentena), `carrega_fatos_auxiliares` (atendimentos e avaliações) e `reconcilia`	**prioridade alta**: `reconcilia` (a mesma fórmula nos dois lados; aborta se a diferença passar de 0,1%) e o tratamento dos itens órfãos em `carrega_fato_item`
`04_abt.py` (parte correta)	`sql_atributos` (o SQL dos atributos, sempre com filtro de data até o corte), `monta_atributos_corretos`, `copia_no_corte` (cria o esquema `dw_corte`: o DW como estaria em 30/06/2025), `verifica_correta` (recalcula o alvo de forma independente em pandas e compara os atributos com os recalculados no `dw_corte`), `grava_correta`, `grava_resumo`	**prioridade alta**: `copia_no_corte` e `verifica_correta`, que são a prova de ausência de vazamento; e o SQL do alvo (`SQL_ALVO`)
`docs/DICIONARIO_ABT.md` e `saida/abt/dicionario_atributos.csv`	cada atributo da ABT, sua regra e o que significa estar ausente	saber explicar cada atributo
`diagnostico/rdt_registros_afetados.py`	números das fichas RDT-10 a RDT-14	consultar

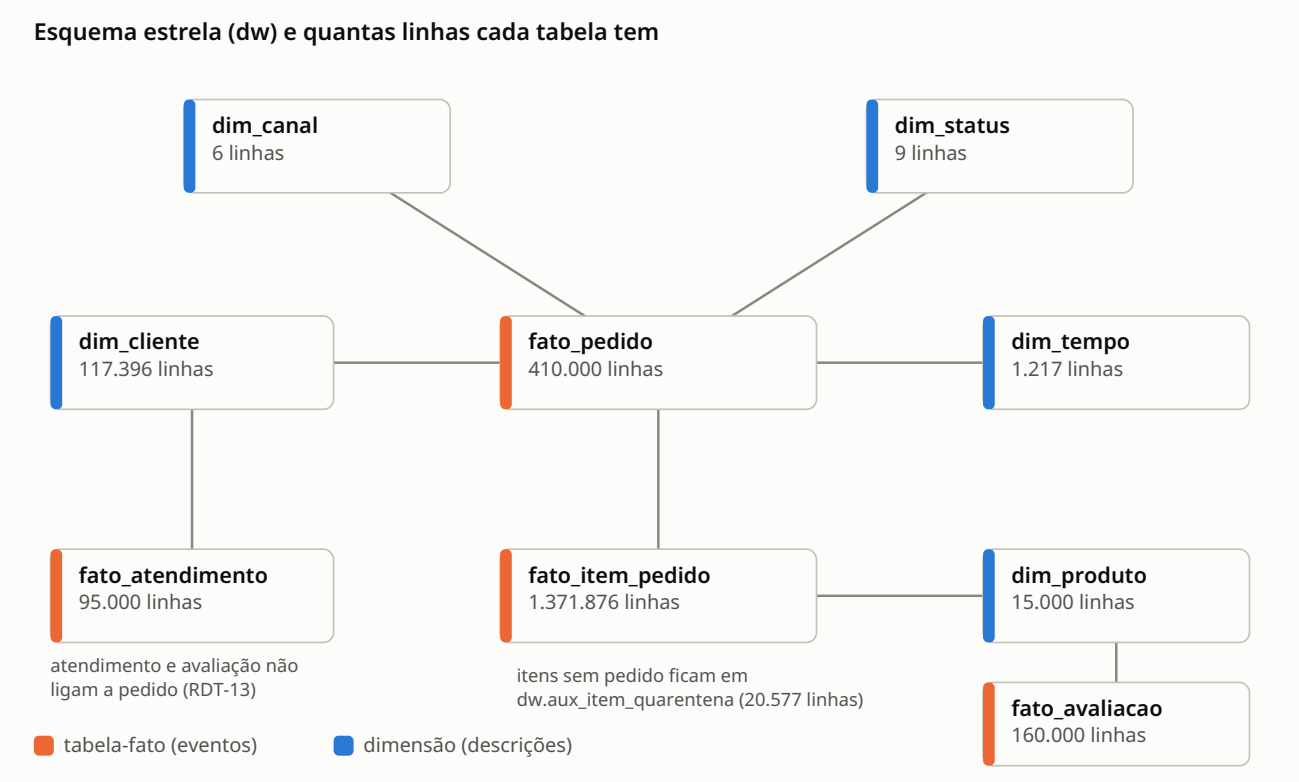


Figura 4. O esquema estrela e o tamanho de cada tabela. Atendimento e avaliação ligam a cliente e a produto, não a pedido.

Resultados

- **Carga:** `fato_pedido` tem 410.000 linhas (130.000 do legado e 280.000 do e-commerce); `fato_item_pedido`, 1.371.876 (98,52% dos itens); `fato_atendimento`, 95.000; `fato_avaliacao`, 160.000. 20.577 itens ficaram em quarentena (1,48%) por não terem pedido. Nenhum pedido ficou sem cliente. 27 asserções, 0 falhas.
- **Reconciliação financeira:** diferença **zero** nos dois sistemas: R$ 281.084.957,13 no legado e R$ 745.850.860,33 no e-commerce. Se a comparação fosse com o `total_amount` cru, apareceria uma diferença falsa de R$ 10.991.760,38 (o frete).

- **ABT:** 109.499 clientes, 24.042 positivos (21,96%), 14 atributos, 12 asserções e 0 falhas. 3.087 clientes só têm pedidos cancelados até o corte (2,82%) e ficam com os atributos "efetivos" nulos.
- **Ausência de vazamento na versão correta:** os atributos foram recalculados com o DW "como estava" em 30/06/2025, e os valores coincidem (asserção `atributos: valores que mudam se o DW for cortado em 30/06/2025`). O teste não cobre o status do pedido, que é o do retrato dos dados (D40).

Interpretação

A reconciliação zero só vale porque a **mesma fórmula** foi aplicada nos dois lados. Ela prova que a carga não perdeu nem inventou valor, não que a fórmula esteja certa; a fórmula vem das evidências da Semana 1. A taxa de 21,96% de positivos mostra um alvo desbalanceado: isso explica por que, na Semana 4, a acurácia simples engana. Há **limites declarados** da ABT: o status do pedido é o do retrato dos dados, não o do dia do corte (D40), e o grupo de clientes só com cancelados fica na população (D38).

Para a defesa

- **Em um minuto:** "Carregamos a estrela, reconciliamos o dinheiro com a origem (diferença zero) e construímos a ABT mostrando, contra o DW cortado em 30/06, que nenhum atributo muda quando os registros do futuro são removidos. O status do pedido é o do retrato dos dados, e isso é um limite declarado."
- **O que é a quarentena?** Itens cujo pedido não existe: ficam numa tabela à parte, com o motivo, fora dos fatos.
- **Por que `fato_pedido` mantém os cancelados?** O grão é "um pedido, qualquer status", e a reconciliação exige todos; excluir os não efetivos é decisão da ABT.
- **Como se mostra que a ABT não vaza?** Recalculando cada atributo com o DW restrito a 30/06/2025 e exigindo valores iguais. Cuidado com o alcance: o teste usa o mesmo SQL nos dois DW e não cobre o status do pedido, que é o do retrato dos dados (D40); por isso dizemos "não encontramos uso de registros posteriores ao corte", e não "provamos que não há nenhum vazamento".

Resumo da semana

Semana 3: carregar, reconciliar e montar a tabela de análise. O DW tem 410.000 pedidos e 1.371.876 itens; 20.577 itens sem pedido ficam em quarentena (27 asserções, 0 falhas). A reconciliação financeira dá diferença zero nos dois sistemas. A ABT tem 109.499 clientes, 14 atributos e 24.042 positivos (21,96%), e passou no teste de equivalência: cada atributo coincide com o recalculado no DW cortado em 30/06/2025 (12 asserções, 0 falhas). **Para levar:** o alvo é desbalanceado, e os limites da ABT estão declarados (status do retrato, clientes só com cancelados, avaliações sem ligação ao cliente).

Semana 4 — Modelar, comparar e defender

O que foi feito

- **Duas versões da ABT.** A *correta* e a *com vazamento*, em que `recencia_dias` e `frequencia_pedidos` são calculados sobre a base inteira (inclusive os pedidos da janela do alvo) e `valor_monetario` é padronizado (z-score) antes da partição treino/teste. A *sutil* tem só a padronização antes da partição.
- **Orange.** Dois fluxos idênticos: amostragem estratificada 70/30, Naive Bayes, Logistic Regression e Tree em *Test & Score*, *Confusion Matrix* e *ROC Analysis*. Só o arquivo de entrada muda (versão 3.40.0).
- **Python.** O mesmo experimento, na partição exportada do Orange, mais a versão sutil e um controle (z-score calculado só no treino).
- **Relatório de resultados**, tabela-resumo e reflexão do RDT (fichas 14 e 15).

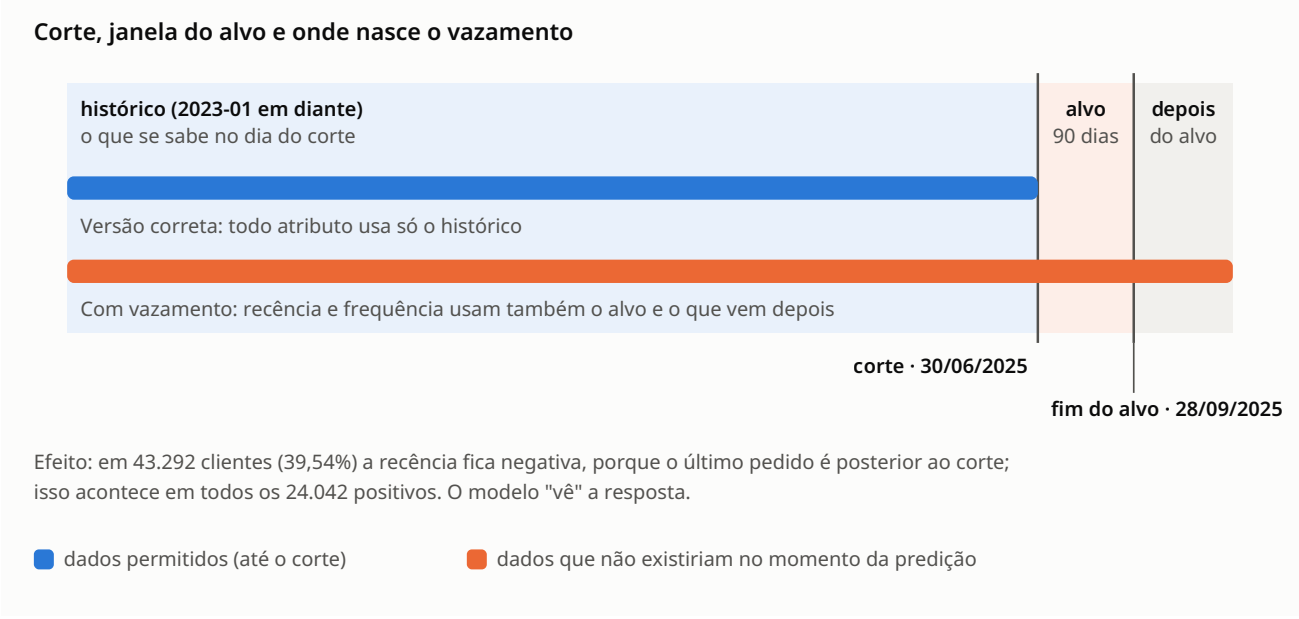


Figura 5. Onde nasce o vazamento: a versão correta só enxerga o histórico; a versão com vazamento enxerga também o alvo.

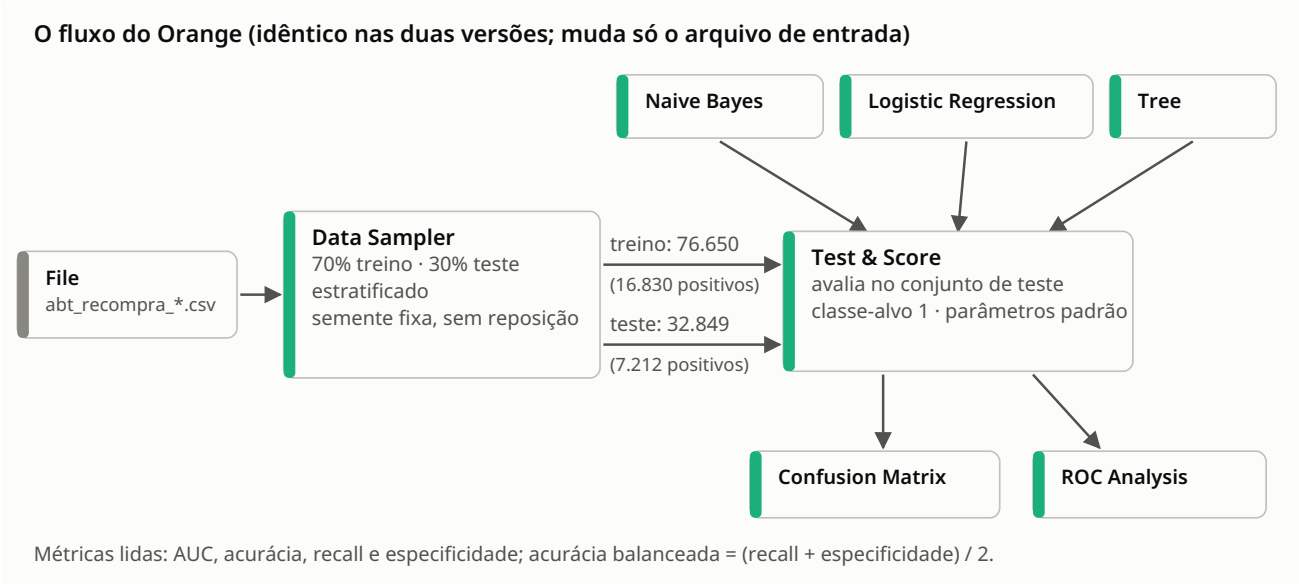


Figura 6. O fluxo que roda nas duas versões. A única diferença entre os dois fluxos é o arquivo lido pelo widget File.

Como executar

```
docker compose exec etl python 04_abt.py --correta --vazamento --vazamento-sutil
docker compose exec etl python 05_exportar_orange.py                      # saida/abt_recompra_{correta,vazamento}.csv
# montar os dois fluxos no Orange: relatorio/semana4/GUIA_ORANGE.md
docker compose exec etl python -m diagnostico.experimento_python         # ~20 s -> saida/experimento/
docker compose exec etl python -m diagnostico.experimento_sensibilidade   # ~5 min
```

O Python lê a partição do Orange (`particao_orange_treino.csv` e `particao_orange_teste.csv`, copiadas para `saida/experimento/`, porque o contêiner não enxerga `relatorio/`).

Código para estudar

Arquivo	O que faz	Estudar
`04_abt.py` (parte do vazamento)	`sql_dois_atributos_sobre_a_base_inteira` (recência e frequência sem filtro de data), `monta_atributos_com_vazamento`, `padroniza_antes_da_particao` (z-score global de `valor_monetario`), `constroi_vazamento`, `verifica_vazamento` (as asserções marcadas "(intencional)" confirmam que o vazamento existe) e `dicionario_vazamento`; as opções `--vazamento` e `--vazamento-sutil`	**prioridade alta**: a diferença entre os três vazamentos
`05_exportar_orange.py`	fornecido: `tipo_orange` e `exporta` gravam o CSV com o cabeçalho de três linhas do Orange (nomes, tipos e papéis)	entender os papéis `class` e `meta`
`diagnostico/experimento_python.py`	`PreProcessador` (indicadores, imputação pela média), `NaiveBayesOrange` (reimplementa o Naive Bayes do Orange), `treina_e_avalia` (três modelos mais a variante padronizada), `auc_univariada` e `main` (partição do Orange, versões, controle, comparação)	**prioridade alta**: `treina_e_avalia` e `main`
`diagnostico/experimento_sensibilidade.py`	testa se a Logistic Regression converge e como o tamanho da folha muda a árvore	saber explicar por que o Python não bate com o Orange
`diagnostico/verificar_resultados.py`	confere os números do relatório de resultados	só para saber que existe
`relatorio/semana4/GUIA_ORANGE.md`	passo a passo dos dois fluxos (não é código, mas é o que vocês executam)	saber refazer um fluxo do zero

Resultados

Treino com 76.650 clientes (16.830 positivos) e teste com 32.849 (7.212 positivos), a mesma partição nos dois fluxos.

Modelo	AUC correta	AUC vazamento	Acurácia balanceada correta	Acurácia balanceada vazamento
Naive Bayes	0,547	0,876	0,520	0,741
Logistic Regression	0,548	0,871	0,500	0,6535
Tree	0,502	0,965	0,507	0,952

(Orange, `metricas_orange.csv`.) O Python dá resultados da mesma ordem (por exemplo, AUC da Tree de 0,505 na correta e 0,959 no vazamento).

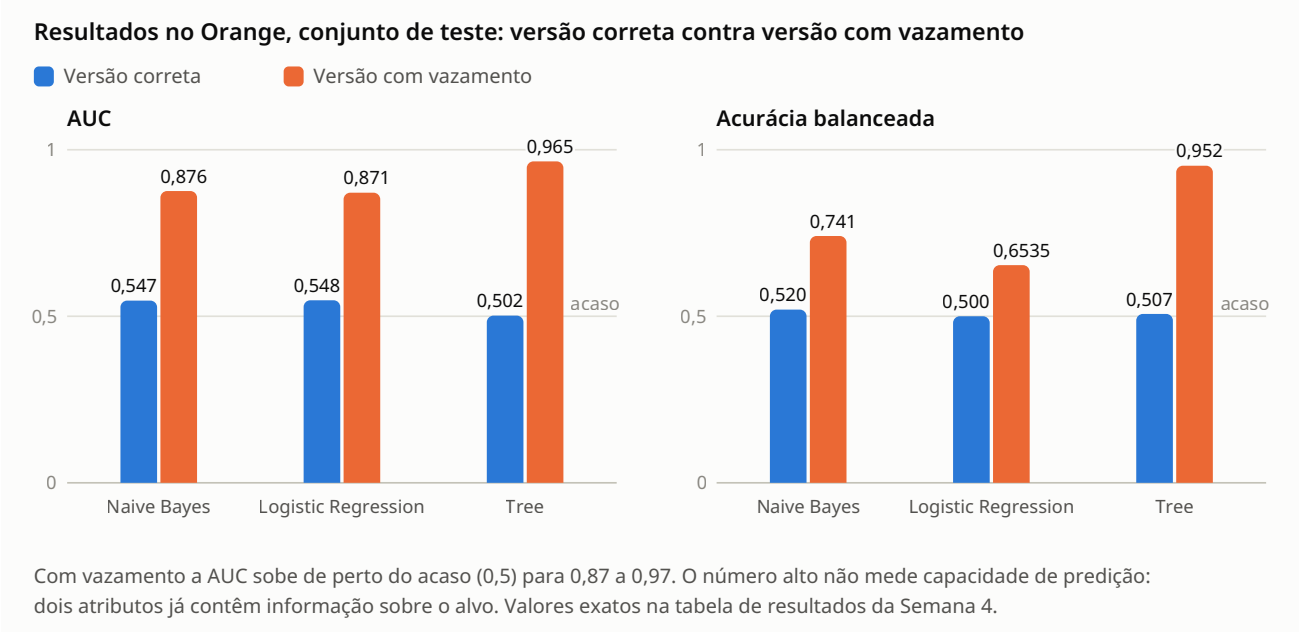


Figura 7. AUC e acurácia balanceada nas duas versões. A linha de 0,5 marca o desempenho de um acaso.

- **O vazamento é medido:** em 43.292 clientes (39,54%) a recência fica negativa, porque o último pedido é posterior ao corte, e isso ocorre em todos os 24.042 positivos.
- **Vazamento sutil:** não deixou rastro. Naive Bayes e Tree dão a mesma AUC da versão correta; a Logistic Regression sem convergência varia 0,014, mas o controle sem vazamento varia quase o mesmo (0,011), e com a otimização convergida as versões ficam iguais.
- **Detecção:** na versão com vazamento, `recencia_dias` sozinho tem AUC 0,797 e `frequencia_pedidos` 0,708; nenhum outro passa de 0,536.

Interpretação

1. **A versão correta quase não prevê** (AUC perto de 0,5): só com histórico de compras, prever a recompra é difícil. O experimento mede o **efeito do vazamento**, não a qualidade de um bom modelo.
2. **A versão com vazamento parece excelente porque trapaceia:** os dois atributos já contêm informação sobre o alvo. O número alto não é capacidade de predição.
3. **O vazamento sutil existe, mas não aparece nas métricas.** Isso ensina que métrica boa ou ruim não prova nem refuta vazamento; só a revisão do código ou da linhagem o revela.
4. **Python e Orange diferem em detalhes** (Logistic Regression e Tree), com explicações plausíveis, não testadas: o Orange para a árvore por maioria de 95%, e o scikit-learn do contêiner não converge a regressão sem normalização.

Para a defesa

- **Em um minuto:** "Construímos a ABT duas vezes e só mudamos o arquivo no Orange: com vazamento, a AUC sobe de cerca de 0,5 para 0,87 a 0,97, porque dois atributos usam pedidos posteriores ao corte."
- **Pergunta (c) do roteiro — se recebesse só o resultado com vazamento, como descobriria que está errado?**
  1. Plausibilidade: AUC de 0,959 numa árvore só com histórico de compras é suspeita.
  2. AUC de cada atributo isolado (executado): `recencia_dias` sozinho tem 0,797, e dois atributos concentram o poder.
  3. Auditoria de linhagem (não executada sobre o resultado, mas é o que fizemos na construção): recalcular os atributos com o DW "cortado" e comparar.
  4. Validação fora do tempo e ablação (não executadas).
- **O vazamento sutil teve efeito?** Não nas métricas; ele só se acha lendo o código (ordem entre padronizar e particionar). Cuidado: dizer "não teve efeito" não é dizer "não existe".
- **Por que acurácia balanceada?** Com 21,96% de positivos, um modelo que sempre prevê "não recompra" teria acurácia alta e recall zero.

- **Por que o Python não bate com o Orange?** São hipóteses não testadas (parada da árvore e convergência); a conclusão (a) vale nos dois.

Resumo da semana

Semana 4: medir o efeito do vazamento. Dois fluxos idênticos no Orange, com só o arquivo de entrada diferente: com vazamento, a AUC sobe de cerca de 0,5 para 0,87 a 0,97, porque dois atributos usam pedidos posteriores ao corte (a recência fica negativa em todos os 24.042 positivos). O vazamento sutil (padronizar antes de particionar) existe, mas não deixou rastro nas métricas. O experimento em Python, na mesma partição, confirma as conclusões e difere do Orange em detalhes explicados por hipóteses não testadas. **Para levar:** métrica alta não prova que o modelo é bom, e métrica igual não prova que não há vazamento; só a revisão da linhagem do dado e do código decide.

Fase final — reprodutibilidade e entrega

O que foi feito

- **Teste do zero:** apagamos o destino (os 5 esquemas do `mercatto_dw` e os arquivos gerados), reaplicamos o DDL e rodamos o pipeline inteiro, comparando impressões digitais (`diagnostico/f1_hashes.py`).
- **Verificadores de números:** `verificar_relatorio.py` (Semana 1), `verificar_resultados.py` (relatório de resultados) e `verificar_documentacao.py` (este documento).
- **README, PDFs** do RDT e do relatório de resultados, e o dump comprimido do DW.

Como executar

```
docker compose exec etl python -m diagnostico.f1_hashes antes      # antes de apagar o destino
# apagar o destino, reaplicar o DDL e rodar o pipeline (ver README, seção 2)
docker compose exec etl python -m diagnostico.f1_hashes depois
docker compose exec etl python -m diagnostico.f1_hashes comparar
```

Código para estudar

Arquivo	O que faz	Estudar
`diagnostico/f1_hashes.py`	`coleta` calcula as impressões digitais (hash dos arquivos; por tabela, linhas e soma de hashes das linhas), `main` grava `antes` e `depois` e `comparar` os compara	por que a soma de hashes não depende da ordem das linhas
`diagnostico/verificar_documentacao.py`	procura cada número deste documento nos arquivos de `saida/`	só para saber que existe
`diagnostico/gera_figuras.py`	gera as figuras deste guia (SVG) lendo os arquivos de `saida/`	ver como cada número da figura vem de um arquivo

Resultados

O teste do zero comparou 196 itens: 185 idênticos e 11 diferentes (`saida/diagnostico/f1_resumo.csv`). Os 11 diferentes são as tabelas da `stg`, que guardam a hora da extração (`_extraido_em`); numa segunda extração, sem essa coluna, as tabelas da `stg` são idênticas (`f1_resumo_stg_a_stg_b.csv`). Todas as tabelas de `cnf`, `dw` e `abt`, os 15 arquivos gerados e as 137 asserções registradas são idênticos.

Interpretação

O pipeline é **reproduzível a partir das origens**. Não provamos que o seed reproduz as origens (não derrubamos os volumes) e a `stg` não é idêntica byte a byte, por construção.

Para a defesa

- **Como se sabe que o pipeline é reexecutável?** Apagamos o destino, rodamos tudo de novo e comparamos hashes de arquivos e de tabelas.
- **O que não foi provado?** O seed das origens e a identidade byte a byte da `stg`.

Resumo da fase

Fase final: provar que se reproduz e que os números têm fonte. O teste do zero comparou 196 itens depois de apagar o destino e rodar o pipeline: 185 idênticos e 11 diferentes só pela hora da extração (`_extraido_em`). Três verificadores conferem os números dos relatórios contra arquivos de `saida/`, e os PDFs do RDT, do relatório de resultados e deste guia estão gerados. **Para levar:** o pipeline é reproduzível a partir das origens; não provamos que o seed refaz as origens.

Como esta documentação foi verificada

Todo número do texto é procurado nos arquivos de `saida/` por `diagnostico/verificar_documentacao.py`:

```
docker compose exec -T etl python -m diagnostico.verificar_documentacao < docs/DOCUMENTACAO.md
```

O resultado fica em `saida/diagnostico/verificacao_documentacao.md`, com a origem de cada número. Se alterarem o texto, rodem o verificador de novo.

As **figuras** não passam por esse verificador (ele lê texto, não imagem). Por isso elas não são desenhadas à mão: `diagnostico/gera_figuras.py` as gera como SVG a partir dos mesmos arquivos de `saida/`.

```
docker compose exec etl python -m diagnostico.gera_figuras
mkdir -p docs/figuras && cp saida/figuras/*.svg docs/figuras/
```

Limitações a saber declarar

- O Orange foi rodado uma vez por versão, e o Python não o reproduz ao centésimo.
- A versão sutil e o controle não passaram pelo Orange.
- A ABT guarda o status do pedido do retrato dos dados, não o do corte (D40), e inclui clientes só com cancelados (D38).
- As avaliações não ligam a cliente (D30); por isso o atributo `nota_media_avaliacoes` ficou fora da ABT.
- A unificação de clientes não tem verdade externa para conferência.