

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE MATO GROSSO — IFMT

Departamento de Computação · Engenharia de Computação · Mineração de Dados
Prof. Orlando Júnior

RELATÓRIO DE DIAGNÓSTICO DAS FONTES — SEMANA 1

Gabriel Lemos Gomes · Lucas Peres de Lima · Marcus Vinícius Santos de Almeida

Cuiabá, 9 de outubro de 2026 · Ambiente gerado com ESCALA=1.0

1 Escopo e método

Medimos as quatro fontes da Mercatto — as tabelas CLIENTES, PRODUTOS, PEDIDOS e ITENS_PEDIDO do MySQL legado, as tabelas customer, category, product, orders e order_item do esquema shop, o CSV do SAC e o NDJSON de avaliações — com seis scripts versionados em etl/diagnostico/ (d01 a d06), executados no contêiner etl com as conexões somente leitura de config.py. Cada número citado vem de um arquivo de saida/diagnostico/, indicado entre parênteses, e está registrado em numeros.json. O script-modelo 00_perfilamento.py trabalha com amostra (LIMIT 200000) e, por isso, trunca ITENS_PEDIDO, orders e order_item; todas as contagens deste relatório agregam as tabelas inteiras, e a reconciliação de valores roda em SQL sobre todos os pedidos. Para executar o perfilamento acrescentamos cryptography a etl/requirements.txt, exigido pelo PyMySQL para autenticar no MySQL 8.

2 Volumes e cobertura temporal

As fontes somam 2.205.864 registros (d01_volumes.csv): 577.336 no legado, 1.372.388 no e-commerce, 96.140 atendimentos e 160.000 avaliações. O total desvia 0,27% do valor declarado no roteiro ($\approx 2,2$ milhões) e 16,1% do declarado no README ($\approx 1,9$ milhão); é o roteiro que corresponde ao ambiente. O CSV tem 97.518 linhas físicas para 96.140 registros, diferença que vem de quebras de linha dentro de campos.

Os dois sistemas cobrem 36 meses, de 2023-01-01 a 2025-12-30, e portanto toda a janela do alvo (d01_volumes_periodos.md). Antes de 01/07/2025 estão 83,13% dos pedidos do legado e 83,4% dos do e-commerce; na janela do alvo, 8,23% e 8,14%; depois dela, 8,64% e 8,45% (d01_periodos_corte.csv). A aquisição de março de 2024 não deixa marca no volume nem na composição: o legado registra 3.615,4 pedidos por mês antes e 3.608,4 depois; o e-commerce, 7.770,9 e 7.782,2; a participação de SITE passa de 35,2% para 34,7% (d01_aquisicao_legado.csv, d01_aquisicao_ecommerce.csv). O dicionário afirma que o ERP opera desde 2016, mas o primeiro cadastro e o primeiro pedido datam de 2023-01-01: o histórico anterior não foi entregue, o que limita qualquer atributo de “tempo de casa”.

3 (a) Chaves de junção

Avaliamos CPF, e-mail e telefone para clientes, e as referências do SAC e do NDJSON para pedidos e produtos. A Tabela 1 resume a cobertura.

Tabela 1 — Cobertura dos candidatos a chave (d02_cobertura.csv, d02_cpf.csv)

Chave	Sentido	Casados	Base	%
CPF válido	CLIENTES → customer	11.875	47.250	25,13
CPF válido	customer → CLIENTES	11.471	85.000	13,5
CPF do SAC	SAC → algum cadastro	90.155	96.140	93,77
E-mail normalizado	CLIENTES × customer	0	47.250	0
Telefone normalizado	CLIENTES × customer	0	47.250	0
(origem, id_pedido)	SAC → pedido no sistema indicado	96.140	96.140	100
CPF do SAC × dono do pedido	SAC → cliente do pedido	1	96.140	0
order.ref	NDJSON → pedido	160.000	160.000	100
product.sku	NDJSON → produto	160.000	160.000	100
order.ref + sku	NDJSON → item do pedido	80	160.000	0,05

O CPF é o único candidato viável entre cadastros. Após manter só dígitos, o legado tem 4.423 CPFs ausentes (9,36%), dois formatos (40.416 com máscara, 2.411 só dígitos) e 38.968 válidos pelo dígito verificador (82,47%); o e-commerce tem 6.855 ausentes (8,06%) e 71.178 válidos (83,74%). Valores com 11 dígitos que falham no verificador somam 3.859 no legado (8,17% dos registros) e 6.967 no e-commerce (8,2%). A unicidade difere: no legado, 1.302 CPFs válidos se repetem em 2.604 linhas; no e-commerce, só 3. A interseção é de 11.470 CPFs válidos distintos, e nos 11.876 pares de registros o nome normalizado concorda em 11.874 (99,98%), o que confirma o CPF como identificador da pessoa. E-mail e telefone não servem: cada sistema usa um único domínio de e-mail, a interseção é zero e, nos pares casados por CPF, o e-mail discorda em 11.876 de 11.876.

As referências a pedido existem, mas não se sustentam. O teste pedido pelo dicionário — `id_pedido_origem` existe no sistema indicado — passa em 100% e ninguém aponta “só para o outro sistema”; porém os identificadores colidem (todos os 130.000 IDs de pedido do legado também existem no e-commerce, `d02_chaves.md`), de modo que a existência não discrimina. O teste de consistência discrimina: o CPF do atendimento é o do dono do pedido em 1 de 96.140 casos, e a abertura do atendimento é posterior ao pedido em 49,81% dos casos, proporção esperada se data e pedido fossem independentes. No NDJSON, o produto avaliado é item do pedido referenciado em 80 de 160.000 avaliações (`d02_ndjson.csv`). Concluímos que SAC e avaliações se ligam ao cliente pelo CPF (93,77% de cobertura no SAC), não ao pedido.

4 (b) Heterogeneidade semântica

Distinguímos heterogeneidade sintática, estrutural e semântica (IFMT, 2026); só a terceira não se resolve por ferramenta e exige reconstruir o significado a partir do dado (SANTOS; DIAS, 2025). Seleccionamos os cinco casos mais fortes (`d03_semantica.md`).

Caso 1 — `VALOR_TOTAL` × `total_amount` (“valor do pedido”). No legado o rótulo inclui o frete; no e-commerce, não (Seção 5). A diferença média entre total e líquido dos itens é 44,28 no legado, igual ao frete médio de 44,31, e 0 no e-commerce, cujo frete médio é 39,26 (`d04_total_vs_frete.csv`). Somar os dois campos mistura grandezas.

Caso 2 — `CANCELADO` × `canceled/payment_declined`. O legado não tem status de recusa de pagamento. `CANCELADO` responde por 12,13% dos pedidos, mais próximo de

canceled + payment_declined (13%) do que de canceled sozinho (8%) (d03_status.csv). Nos dois sistemas, cancelados e recusados não têm data de entrega (15.774 de 15.774; 36.403 de 36.403), têm itens e mantêm o valor cheio (média de 2.160,8 em CANCELADO, 2.651,28 em canceled e 2.644,81 em payment_declined, contra 2.162,58 em ENTREGUE). A consequência é que CANCELADO provavelmente agrega dois significados que o e-commerce separa, e a origem não permite desfazê-los: a coluna motivo_cancelamento da dim_status ficará nula para o legado.

Caso 3 — SITE × web, e channel no NDJSON. SITE não se comporta como um canal digital: seus pedidos ocorrem só entre 8h e 21h, como LOJA e TELEVENDAS, com 0% entre 22h e 8h, enquanto web registra 41,67% dos pedidos nessa faixa (d03_channel.csv). DT_PEDIDO é descrito como “fechamento do pedido”; os dados sugerem que, no legado, o pedido do site é registrado em horário comercial, e não no instante da compra. Além disso, LOJA tem frete positivo em 99,75% dos pedidos, o que indica entrega e não venda de balcão. No NDJSON, order.channel vale marketplace em 100% das avaliações, mas apenas 18,21% dos pedidos ECOM referenciados são de marketplace (d03_channel_ndjson.csv): ali o rótulo designa a plataforma da avaliação, não o canal da venda.

Caso 4 — Categoria. O legado tem 27 textos distintos byte a byte; o GROUP BY do MySQL mostra 24, porque a collation latin1_swedish_ci ignora caixa e acento e esconde 3 variantes; após normalização restam 23 rótulos não vazios e 103 produtos sem categoria (3,43%) (d03_categoria_mapa.csv). A taxonomia do e-commerce tem 21 nós, mas os produtos ocupam só as 15 folhas. Dos rótulos do legado, 8 mapeiam diretamente (30,53% dos produtos), 11 correspondem a uma raiz com filhos e não descem ao nível em que o e-commerce classifica (47,43%), 2 são ambíguos — ELETR0 e informatica e games (10,7%) — e 3 não têm mapeamento — DIVERSOS, OUTROS e vazio (11,33%). A descrição não ajuda a desempatar: em ambos os sistemas, cada um dos 50 substantivos iniciais das descrições aparece em 15 ou mais categorias.

Caso 5 — Notas de 1 a 5. nota_satisfacao é texto, com 2.830 zeros (2,94%) e 8.682 vazios; rating chega como inteiro em 139.061 avaliações, como texto em 16.108 e ausente em 4.831 (d03_notas.csv). As distribuições de 1 a 5 são praticamente uniformes nas duas fontes (médias de 2,996 e 3,006), o que não permite afirmar nem negar que as escalas sejam a mesma; o zero do SAC não se concentra em atendimentos sem fechamento (6,36% contra 6,09% no geral), e seu significado permanece desconhecido.

Dois hipóteses do roteiro caíram. O desconto é por linha nos dois sistemas: a razão desconto/(quantidade × unitário) fica estável entre 5,73% e 5,99% no legado, enquanto a razão desconto/unitário cresce de 5,73% para 17,97% com a quantidade (d03_desconto.csv). E o formato do CPF não varia no tempo: a fração só de dígitos fica entre 4,87% e 5,25% em todos os anos de cadastro (d03_cpf_tempo.csv).

5 (c) Semântica dos valores

Reconciliamos, em SQL e para todos os pedidos, o total gravado com a soma dos itens, com tolerância de 0,01 (d04_valores.py).

Tabela 2 — Pedidos que satisfazem cada hipótese (d04_resumo.csv)

Hipótese	Fórmula	Legado (%)	E-commerce (%)
H1	bruto	0,02	0
H2	bruto – desc_linha	0,02	100
H3	bruto – desc_linha + frete	96,92	0,02
H4	bruto + frete	0,23	0
H5	bruto – desc_unid	0	8,25
H6	bruto – desc_unid + frete	9,58	0,01
H3 com –1 tratado como 0		100	0,02

Os dois campos não medem a mesma coisa. `total_amount` é o valor líquido da mercadoria, sem frete (H2 em 280.000 de 280.000 pedidos). `VALOR_TOTAL` é mercadoria líquida mais frete (H3). Os 4.003 pedidos do legado que não satisfazem H3 são exatamente os que contêm desconto –1: o resíduo vale –1 em 3.950 pedidos e –2 em 53, igual ao número de linhas com o sentinela (`d04_residuos_legado.csv`). O sistema que calculou o total tratou –1 como “sem desconto”; com essa leitura, H3 explica 100% dos pedidos. O resultado é idêntico antes e depois de março de 2024, em todos os canais e em todos os status (`d04_hipoteses.csv`), e não há pedidos sem itens em nenhum sistema. Pedidos com frete negativo (362 no legado e 812 no e-commerce) também satisfazem as hipóteses vencedoras: o frete negativo entra na conta como está, e seu significado (estorno? subsídio?) não se decide pelo dado. Para a reconciliação financeira da Semana 3, a referência é 281.084.957,13 de `VALOR_TOTAL` e 734.859.099,95 de `total_amount` (`d04_somas.csv`), que não podem ser somados sem antes retirar 5.760.932,57 de frete do legado.

6 (d) Anomalias

Uma anomalia é quantificável agora quando aparece dentro de uma única fonte; ela só aparece depois da integração quando depende de pôr duas fontes na mesma régua — uma chave, um fuso, uma definição de cliente. Os problemas do segundo grupo são os que se propagam silenciosamente até a ABT, o que Sambasivan et al. (2021) chamam de *data cascades*.

Tabela 3 — Anomalias quantificáveis agora (d05_agora.csv)

Fonte	Anomalia	n	%
Legado	Pares de clientes com mesmo e-mail, telefone e nome	2.250	9,52 das linhas
Legado	DT_ENTREGA = 1900-01-01 (todos ENTREGUE)	1.025	0,79
Legado	Entrega anterior ao pedido	775	0,6
Legado	ITENS_PEDIDO sem pedido	5.868	1,48
Legado	VL_DESCONTO = –1	4.056	1,02
Legado	CIDADE = 'N/A'	933	1,97
E-commerce	order_item sem pedido (IDs acima do maior pedido)	14.709	1,48
E-commerce	Entrega anterior ao pedido	1.683	0,6
Ambos	Frete negativo	362 / 812	0,28 / 0,29

Fonte	Anomalia	n	%
SAC	Linhas idênticas excedentes	1.140	1,19
SAC	Quebra de linha em motivo	1.377	1,43
SAC	Tempo de resolução negativo	353	0,37
NDJSON	rating como texto / ausente	16.108 / 4.831	10,07 / 3,02
NDJSON	submitted_at sem offset	31.915	19,95

Não há pedidos sem cliente, pedidos sem itens nem itens sem produto, e nenhum preço unitário ou de tabela é zero ou negativo. Os itens órfãos do e-commerce têm `order_id` a partir de 280.002, acima do maior pedido existente (280.000), compatível com a gravação assíncrona mencionada no DDL.

Tabela 4 — Anomalias que só aparecem depois da integração (d05_depois.csv)

Anomalia	Inferior	Superior	Por que só depois
Registros de CLIENTES com par no e-commerce	11.875	15.793	exige cruzar os cadastros; o superior acrescenta pares por nome e UF quando falta CPF válido
Atendimentos cujo CPF está só no cadastro do outro sistema	1.620	26.671	o CSV declara o sistema; a contradição só aparece contra os dois cadastros
Pedidos que trocam de lado do corte ou do fim do alvo conforme o fuso	60	78	o legado não tem fuso e o e-commerce tem; o lado da fronteira depende da régua comum
Cientes cujo rótulo do alvo muda com o fuso	44	58	o rótulo é calculado sobre a base integrada
Cientes de CPF comum com compras antes do corte nos dois sistemas	9.681	13.599	cada sistema vê só parte do histórico
Cientes de CPF comum cujo rótulo difere entre um sistema e a visão integrada	3.681	7.599	a recompra pode ter ocorrido no outro sistema

O limite superior de clientes comuns é frouxo por construção: entre registros com CPFs válidos e diferentes, 787 coincidem em nome e UF, ou seja, nome e UF produzem homônimos (d05_anomalias.md). Na janela de 20h às 4h em torno de 30/06/2025, há 71 pedidos do e-commerce e 24 do legado (d05_fuso_fronteras.csv). O efeito mais forte é o histórico dividido: dos 11.409 clientes de CPF comum com histórico, 84,85% compraram nos dois sistemas antes do corte, e a média de pedidos por pessoa passa de 2,61 (só legado) ou 2,93 (só e-commerce) para 5,13 quando integrada. Sem unificação, 32,26% dessas pessoas teriam ao menos uma linha da ABT com rótulo errado.

7 (e) Grão

O grão é a definição explícita do que uma linha da tabela-fato representa (KIMBALL; ROSS, 2013). Verificamos no dado as condições que o sustentam (d06_grao.md): `ID_PEDIDO` e `order_id` são únicos em cada sistema (130.000 e 280.000 valores distintos), mas os 130.000 IDs do legado colidem com o e-commerce, de modo que a união sem o sistema teria 280.000

pedidos em vez de 410.000. O mesmo produto aparece em mais de uma linha do pedido em 195 pares no legado e 128 no e-commerce, e as duas linhas têm preços diferentes em todos os pares menos 1 e 2, respectivamente: são vendas distintas, não duplicatas.

Uma linha de `dw.fato_pedido` representa um pedido registrado em um dos dois sistemas de origem, identificado pelo par (sistema de origem, identificador do pedido na origem), qualquer que seja o seu status.

A chave natural inclui o sistema porque só o par é único. Cancelados e recusados permanecem na tabela porque são pedidos — têm itens e valor — e porque a reconciliação financeira contra a origem exige todos os pedidos; excluir os não efetivos (15.774 no legado, 36.403 no e-commerce, `d06_status_abt.csv`) é decisão da ABT, tomada pela `dim_status`, e não do grão.

Uma linha de `dw.fato_item_pedido` representa uma linha de item tal como registrada na origem (`ID_ITEM` ou `order_item_id`), pertencente a um pedido presente em `dw.fato_pedido`.

Agregar por (pedido, produto) misturaria linhas de preços diferentes. Os itens órfãos não entram, porque não têm pedido a que pertencer.

8 Questões em aberto para a Semana 2

Questão indecível com o dado atual	Ficha
Carga completa ou incremental: as origens não têm coluna de atualização, e itens chegam antes do pedido (14.709 órfãos)	RDT-01
Unificar só por CPF válido ou aceitar nome + UF, sabendo que este gera 787 homônimos	RDT-02
Qual registro sobrevive nos 2.250 pares duplicados do legado	RDT-03
Se CANCELADO inclui recusa de pagamento; a origem não separa os dois	RDT-04
Conformar <code>valor_total</code> como mercadoria + frete – desconto para os dois sistemas	RDT-05
Significado do frete negativo (362 + 812) e tratamento do desconto –1 (4.056 linhas)	RDT-06
Rótulos de nível raiz, ambíguos (321 produtos) e sem mapeamento (340)	RDT-07
Nota 0 do SAC, <code>rating</code> ausente, CPF inválido, <code>DT_ENTREGA</code> sentinela, <code>CIDADE</code> = 'N/A'	RDT-08
Fuso de <code>DT_PEDIDO</code> e das 31.915 avaliações sem offset; régua única para o corte	RDT-09
Ligação de SAC e avaliações: pelo CPF, ao cliente; o vínculo com o pedido não se sustenta	RDT-13

Referências

IFMT. *ETL como preparação de dados na mineração de dados: fundamentos, decisões e implicações didáticas*. Referencial teórico da disciplina de Mineração de Dados. Cuiabá: IFMT, 2026.

KIMBALL, Ralph; ROSS, Margy. *The data warehouse toolkit: the definitive guide to dimensional modeling*. 3. ed. Indianapolis: Wiley, 2013.

SAMBASIVAN, Nithya et al. “Everyone wants to do the model work, not the data work”: data cascades in high-stakes AI. In: CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2021, Yokohama. *Proceedings* [...]. New York: ACM, 2021.

SANTOS, Sarah Rúbia de Oliveira; DIAS, Célia da Consolação. Panorama das abordagens de integração de dados: um estudo da produção científica brasileira em Ciência da Informação. *Brazilian Journal of Information Science*, v. 19, p. e025012, 2025.

Apêndice — Comandos de reprodução

```
cd ETL
printf 'ESCALA=1.0\n' > .env
docker compose up -d --build          # aguardar "ambiente pronto." em docker
↪ compose logs seed
docker compose exec etl python 00_perfilamento.py
for s in d01_volumes_periodos d02_chaves d03_semantica d04_valores d05_anomalias
↪ d06_grao; do
    docker compose exec etl python -m diagnostico.$s
done
docker compose exec etl python -m diagnostico.verificar_relatorio
```